

K-Buddy

체류자격 기반 외국인 금융정착 AI Agent

기능 개요서

공개된 1차 출처에 근거해서만 금융 절차를 안내하고,
근거가 없거나 개별 심사 영역이면 **답하지 않는 것을 설계로 강제한다.**
— 안전성 주장이 프롬프트가 아니라 코드에 있다.

기능	필수 F1-F5 · 확장 F6-F8 (8/8 구현 완료)
화면	11개 라우트 · UI 6개 언어 (원어민 검수 3개)
검증	자동 테스트 536개 · 골든셋 160문항 · 실험 리포트 12회
작성일	2026-09-07

8개 기능 중 생성 모델을 쓰는 것은 두 개(F4·F5)뿐이다. 나머지 여섯은 규칙·템플릿·순수 함수·공공 OpenAPI 로 구성되어 있고, 이는 성능 한계가 아니라 의도된 선택이다 — 금액 계산과 사기 판정, 은행 요건 조회는 틀렸을 때 이용자가 손해를 보는 영역이라 생성 모델에 맡기지 않는다.

#	기능	구분	성격	핵심 산출물	계층
F1	다국어 온보딩	필수	규칙 (자유 입력 0)	세션 프로필 SessionContext	—
F2	계좌개설 내비게이터	필수	규칙만 · LLM 없음	기관 카드 + fit_score 정렬	B C
F3	서류 체크리스트	필수	템플릿 · PDF 조판	모국어 / 한국어 2열 병기 PDF	B C
F4	한도제한계좌 해제 가이드	필수	RAG + LLM	SSE 스트림 + F3 후속 액션	A B C
F5	근거 기반 QA 챗봇	필수	RAG + LLM (①~⑩)	SSE 스트림 + 인용 배치	A B C
F6	해외송금 시뮬레이터	확장	순수 함수 + 한국은행 ECOS	당일 고시 환율 환산 · 한도 안내	B
F7	금융상품 비교	확장	금감원 OpenAPI + 정렬	예금·적금·신용대출 비교 카드	B
F8	사기 유형 대조	확장	정적 체크리스트 · 판정 없음	유형 대조표 + 대응 절차·연락처	C

응답 계층 — 모든 답변에 붙는 신뢰도 등급

계층은 모델이 스스로 신고하는 값이 아니다. 파이프라인 ⑨ tiering/postprocess.py 가 근거를 보고 확정하며, 모델이 A 라고 말해도 강등된다.

계층	의미	화면 처리
A	법령·규정·기관 공식 안내에 명시	파란 출처 배치 + 인용 링크
B	통상적 경향	"일반적으로" 문구 + 사전확인 권고를 강제 삽입
C	개별 심사 결과	생성 금지. 공식 채널(1332 등) 안내로 대체

강등 규칙: 근거가 정부 문서가 아니면 A→B, 오래된(stale) 문서가 섞이면 A→B. 계층 C 는 검색을 실행하기도 전에 규칙이 선판정해 차단하므로 생성 호출 자체가 일어나지 않는다.

"환각하지 않는다"는 프롬프트로 약속할 수 없다. K-Buddy 는 그 주장을 네 곳의 **순수 함수**에 넣어 단위 테스트로 지킨다.

방어선	구현 위치	막는 것
② 계층 C 선편정	app/tiering/rules.py	개별 승인·한도·금리 예측 질의를 LLM 호출 전에 차단 (0ms, 검색 미실행)
⑧ 출력 검사	app/tiering/postprocess.py	인용 존재 → 인용 실재성 → 숫자 대조 → 금지표현 → 민감정보 요구
⑨ 계층 최종 확정	app/tiering/postprocess.py	모델이 신고한 계층을 근거 기준으로 재판정·강등
숫자 정규화	app/util/numerals.py	답변의 모든 수치를 근거 텍스트와 대조

숫자 대조가 가장 실용적인 환각 방어다. 1,000,000원 · 100만원 · 백만원 · 일백만원 을 같은 값으로 취급하고, 5만 달러 와 5만 원 은 다른 값으로 취급한다. 근거에 없는 숫자가 하나라도 있으면 답변 전체가 폐기되고 폴백 카드로 교체된다.

설계 원칙 네 가지

원칙	적용 사례
근거가 없으면 숫자를 내지 않는다	F6 송금 한도는 1차 출처를 확보하지 못해 unknown 으로 나간다. "한도를 넘지 않았다" (exceeds=false)고도 말하지 않는다 — 근거 없는 안심이 근거 없는 경고보다 위험하다.
미확인을 0 으로 접지 않는다	F2 fit_score 는 확인 못 한 항목을 분모에서 뺀다. 0 으로 계산하면 확인 못 한 은행이 "나쁜 은행"으로 정렬된다. F7 도 같다 — 공시 없는 금리를 0% 로 접으면 미공시 대출이 1위가 된다.
못 가져온 것 ≠ 없는 것	F7 은 외부 API 장애 시 빈 목록이 아니라 available=false 를 낸다. 빈 목록은 화면에서 "그런 상품이 없다"로 읽힌다. 502 도 내지 않는다 — "우리 서비스가 고장났다"로 읽히기 때문이다.
판정하지 않는다	F8 은 사연을 받는 인자 자체가 없고, 응답 스키마에 verdict.is_scam_risk 같은 자리를 두지 않는다. 체크 개수를 판정으로 바꾸는 임계값도 없다.

거짓 폴백보다 거짓 생성을 훨씬 무겁게 취급한다

답할 수 있는데 답하지 않는 것(과잉 폴백)과 근거 없이 답하는 것(환각) 중, 임계값 캘리브레이션은 **후자를 훨씬 무겁게** 잡는다. 그 결과 과잉 폴백률이 목표치를 넘지만(\$5), 이는 의도된 트레이드오프다.

F1 다국어 온보딩

규칙 기반 · LLM 없음

체류자격·거래목적을 파악해 이후 모든 안내를 개인화한다. 동시에 **수집 범위를 여기서 못 박아** 서비스 전체가 식별정보를 다루지 않게 만든다.

입력	국적(ISO 3166-1 alpha-2) · 체류자격(12종 열거) · 체류기간(4구간) · 거래목적(최대 5개) — 전부 선택 사항
출력	sessionStorage 의 SessionContext. 서버로 전송되지만 저장되지 않는다
화면	S1 / [locale] 언어 선택 → S2 / [locale] / profile 4단계 선택 + 진행률 바
검증	test_schemas.py — 대문자 정규화 · 열거값 외 거절 · 하이픈 표기(E-9) 고정

자유 입력 필드가 하나도 없다. 전부 선택지다. 개인정보 최소 수집의 구현이자, 프롬프트 인젝션 표면을 온보딩 단계에서 0 으로 만드는 설계다. localStorage 는 금지 — 공용 PC 를 상정해 sessionStorage 만 쓴다.

체류자격 12종 선정 근거: 법무부 2026-06 통계 기준 합계 1,973,900명 = 체류외국인의 68.7%. 빠진 상위(B-2·C-3·B-1)는 전부 단기체류라 계좌개설 대상이 아니다.

F2 계좌 개설 내비게이터

규칙만 · LLM 호출 없음

체류자격을 기준으로 어느 은행에서 무엇이 확인됐는지를 보여준다. 이 기능의 값어치는 "가장 좋은 은행"을 고르는 데 있지 않고 **확인 된 것과 확인하지 못한 것을 갈라 보여주는 데 있다.**

입력	GET /institutions — lang, visa (둘 다 선택)
처리	요건 매트릭스 로드(프로세스당 1회 캐시) → 불변식 검증 → fit_score 순수 함수 → 응답 조립
출력	기관 카드(fit_score 내림차순) + unknown_institutions 별도 배열 + 계층 + 갱신일
화면	/[locale]/institutions — InstitutionCard · UnknownNotice · TierNotice
검증	test_matrix.py 27케이스 — 근거 없는 official 셀은 로드 시점에 ValueError

fit_score = 0.5×visa_fit + 0.3×doc_burden + 0.2×channel_access. 산식은 GET /institutions/ranking-policy 가 **코드 상수를 직접 읽어** 공개한다 — 문서용 사본을 두지 않는다(두 곳에 적으면 반드시 어긋난다). 아는 항목이 하나도 없으면 점수는 0.0 이 아니라 null 이다.

unknown_institutions 를 카드 배열에 섞지 않고 최상위에 따로 두는 이유: 회색으로 칠해 섞으면 "정보가 있는데 좀 흐린 것"으로 읽힌다.

창구에서 그대로 보여주는 용도. 모국어와 한국어를 2열로 병기해, 이용자가 서류 이름을 한국어로 말하지 못해도 종이를 내밀 수 있게 한다.

입력	lang(필수) · visa · purpose · inst_code · include_ko(기본 true)
출력	POST /checklist → PDF 스트리밍 (Cache-Control: no-store, 서버 저장 없음) POST /checklist/preview → JSON (화면 내 HTML 체크리스트)
화면	S5-1 / [locale] / tools / checklist — F4 응답에서 조건을 그대로 물고 진입
검증	test_checklist.py 27케이스 + 컨테이너 조판 검증

성격이 다른 세 목록을 한 표에 섞지 않는다. ① 공통 신분 서류(금융위) · ② 계좌개설·한도해제 증빙(금융위, **은행 창구** 제출) · ③ 외국인등록 제출서류(법무부, **출입국·외국인청** 제출). 섞으면 이용자가 **재학증명서를 들고 은행에 간다** — 발급 기관도 제출처도 다르다.

②의 원문은 "증빙 서류(예시)"이고 은행마다 다르므로 절마다 주의문구를 함께 싣는다. 근거가 있는 조합만 적고, 금융위 예시 표에 없는 목적(학비·생활비·송금)은 **의도적으로 빈 절로 남긴다** — "확인하지 못했다"는 것 자체가 답이다. 서류명 라벨은 사전(glossary.csv)이 소스이며 **LLM 번역에 맡기지 않는다**.

조판 실측(2026-08-20): ko 698자 → Noto-Sans-CJK-KR, vi 1,597자 중 성조 149자 정상 합성, 결합기호 분리 0건, 폰트·글리프 경고 0건. **통과**. 검증은 텍스트 비교가 아니라 **글자별 폰트명 대조**다 — 두부(口)로 찍어도 텍스트 비교는 통과하기 때문이다.

F4 한도제한계좌 해제 가이드

RAG + LLM

"왜 100만 원까지만 보낼 수 있나"에서 시작해 **한도를 풀려면 무엇을 내야 하는지**까지 잇는다. 체류자격 × 거래목적으로 증빙 조합이 갈리므로 RAG 가 필요하다.

입력	POST /guide/limit-release — lang + F1 프로필. 새로 묻는 것이 없다
처리	프로필 → 한국어 질의 조립 → F5 와 같은 ChatPipeline 인스턴스 ①~⑩ → 후속 액션 부착
출력	F5 와 동일한 SSE 이벤트 순서 + done 에 실리는 next_action (F3 체크리스트 연결)
화면	S3 대시보드 카드 · S4 챗봇 질의 — 진입점 2개, 응답 후 F3 로 연결
검증	test_guide.py 16케이스 + 골든셋 Q-LIMIT-* 34문항

새 생성 경로를 만들지 않는다. ChatPipeline 이 ①~⑩ 을 이미 관통하고, F4 가 더하는 것은 앞뒤 둘뿐이다 — 질의 조립과 후속 액션. **질의를 한국어로 조립하는 것이 핵심이다** — 챗봇 경로는 사용자 언어를 ③ 정규화가 한국어 검색어로 옮기는데 그 품질이 en 86.4% / vi 90.5% 로 목표(92)에 못 미친다. F4 는 질의를 **우리가 만들기 때문에** 정규화를 통과할 필요가 없고, 답변 언어는 lang 이 정하므로 다국어성도 잃지 않는다.

폴백일 때는 next_action 을 붙이지 않는다. 답하지 못한 뒤에 "이 서류로 체크리스트를 만드세요"를 내밀면 답한 척이 된다. 서버가 판단하므로 클라이언트는 다시 보지 않는다.

다국어 질의에 대해 **공개된 1차 출처에 근거해서만** 답한다. 근거가 없거나 개별 심사 영역이면 **답하지 않는 것**을 설계로 강제한다. 개발 전체의 최대 덩어리.

입력	POST /chat — lang(필수) · message(1~2,000자) · 프로필 · 히스토리(최근 6턴만 절삭)
출력	SSE: meta → token* → citations → (invalidate) → done
화면	S4 /[{locale}]/chat — MessageList · CitationBadge · TierNotice · AiDisclosure
검증	골든셋 160문항(ko 77 / en 42 / vi 41) + 자동 채점 하니스 eval/run_eval.py

- ① 입력 가드레일 규칙 인젝션 중화 · PII 마스킹
- ② 계층 C 선판정 규칙 ★ 0ms · 검색조차 실행하지 않고 차단 (ko·en·vi 각각 패턴 보유)
- ③ 질의 정규화 사전+소형LLM 이용자 언어 → 한국어 검색어
- ④ 하이브리드 검색 규칙 BM25 + 임베딩 → RRF (원 41ms)
- ⑤ 리랭킹 — 미도입 확정 (ADR-001) — RRF 상위 5건 직행
- ⑥ 컨텍스트 조립 규칙
- ⑦ 생성 LLM 구조화 출력 · answer 가 첫 필드 (스트리밍 TTFT)
- ⑧ 출력 가드레일 규칙 ★ 인용 실재성 → 숫자 대조 → 금지표현 → 민감정보
- ⑨ 계층 최종확정 규칙 ★ 모델이 신고한 계층을 근거 기준으로 재판정
- ⑩ AI 생성 표시 UI 상시 고지

②와 ⑨가 이 서비스의 심장이다 — "프롬프트가 아니라 아키텍처로 강제한다"는 주장의 실제 구현체이며, 둘 다 프레임워크 밖 순수 함수로 두어 단위 테스트가 가능하다. 판정은 전부 규칙이고 LLM 은 ⑦ 생성 하나에만 들어간다(③의 소형 보조 제외).

검색 토큰라이저 — 변별력의 실제 소재

- 도메인 복합명사 24종을 고유명사로 등록 — "한도제한계좌"가 한도/제한/계좌로 쪼개지면 "한도 제한 있는 계좌"류 무관 문서까지 매칭되어 변별력이 사라진다.
- 체류자격 코드를 형태소 분석 전에 정규식으로 보호. 임베딩만으로는 E-9 와 E-7 이 거의 같은 벡터가 되므로, BM25 가 둘을 다른 토큰으로 취급하는 것이 혼동 방지의 핵심이다.
- E-9 / E9 / e-9 를 같은 토큰으로 정규화 — 문서와 질의의 표기가 다르다.

예외 처리

상황	처리
입력 오류	422. 길이 초과는 절삭이 아니라 거절 (2,000자는 정상 질의 범위를 크게 넘음)
검색 실패	top1 < 언어별 임계값 → low_confidence 폴백 + 금융감독원 1332 안내
외부 API 장애	재시도 2회 → 대체 모델 폴백 → 그래도 실패 시 upstream_error
모델 거절	stop_reason=refusal → model_refusal. content 를 읽기 전에 분기
계층 C	검색 전 선판정에서 차단. 생성 호출 자체를 하지 않음
출력 검사 실패	invalidate 이벤트 → 화면에 흘러간 텍스트를 폴백 카드로 교체

meta 의 계층은 **잠정값**이고 최종은 done 에서 확정된다. invalidate 처리를 빠뜨리면 "차단했다"고 주장하면서 화면엔 환각이 남는 사고가 난다 — 그래서 F4 화면에도 같은 처리를 넣었다.

F6 해외송금 시뮬레이터

순수 함수 + 한국은행 ECOS

보내려는 금액을 당일 고시 매매기준율로 환산하고, **확인된 한도만** 안내한다. "얼마까지 보낼 수 있는가"를 단정하는 기능이 아니다.

입력	lang · amount_krw(>0, 필수) · self_declared_ytd_usd(자가 입력값)
처리	ECOS 환율 조회(1시간 캐시) → 환산(순수 함수) → 한도 카탈로그 로드 → 연간·건당 판정
출력	환산액 + 환율(값·고시일·출처·기준·stale 여부) + 연간 / 건당 한도 + 계층 B
화면	S5-2 / [locale]/tools/remittance · 대시보드 카드
검증	test_remittance.py 16케이스 — 실키 없이 돈다

LLM 이 없다. 금액 계산을 생성 모델에 맡기면 숫자 대조로도 잡히지 않는다 — 근거에 **없는** 값이 아니라 **계산이 틀린** 값이기 때문이다.

한도 수치의 근거를 아직 확보하지 못했다. 기능은 완성되어 있으나 한도는 unknown 으로 나가고 **금액을 표시하지 않는다.**

remaining·exceeds 가 모두 None 이며, exceeds=false("한도 안이다") **조차 내지 않는다** — 초록 배지 하나가 근거 없는 안심을 준다. 코드가 이를 강제한다: 근거 없이 상태를 올리면 기동 시 SystemExit.

환율 실키 검증 완료(2026-08-21) — 1,393.00 원/USD, 고시 2026-08-21, stale=false. ECOS 는 **일별 고시**라 실시간 시세가 아니므로 quoted_at 이 필수이고, 고시일이 3일을 넘으면 is_stale=true + 화면 경고가 붙는다 — 옛 환율을 조용히 쓰지 않는다. used_is_self_declared 는 **항상 true** 다. 이 서비스는 외환거래 전산망을 조회하지 않으며, 조회하는 것처럼 보이면 이용자가 이 숫자를 공식 잔액으로 믿는다.

F7 금융상품 비교

금감원 OpenAPI + 정렬

금융감독원 「금융상품 한눈에」 공시로 **상품 조건**을 비교한다. 가입 가능 여부를 판단해 주는 기능이 아니다.

입력	kind(정기예금 / 적금 / 신용대출) · save_trm(저축기간) · limit(1~100) · lang
처리	FSS 조회(하루 1회 캐시) → baseList+optionList 조인 → 필터·정렬 → 정렬 기준 공개
출력	비교 카드 + available 플래그 + sort_policy + 계층 B
화면	/ [locale]/tools/products — 종류 탭 3개 + 기간 선택, 주의문구가 목록보다 위에 상시
검증	test_products.py 15케이스(픽스처 주입, 실키 없이 돈다) + 실키 검증 완료

이 API 는 외국인 가입 가능 여부를 제공하지 않는다. join_deny(1/2/3)·join_member 는 체류자격을 다루지 않으므로, join_deny=1("제한 없음")을 "외국인도 가능"으로 옮기는 순간 그것이 환각이다. 원문 코드를 **그대로** 싣고, 가입 가능 여부는 화면과 정렬 정책 양쪽에서 "해당 금융기관에 직접 확인"으로 명시한다.

정렬에 들어가는 값은 공시 금리 하나뿐이고, **들어가지 않는 것**(제휴 여부·광고비·수수료 수취·은행 규모·조회수)을 응답에 함께 싣는다. 선택한 기간의 금리가 없는 상품은 목록에서 빼고(빈 칸은 화면에서 "0%"로 읽힌다), 공시 없는 금리는 sort_value=null 로 두어 맨 뒤에 놓는다.

실키 검증(2026-08-21): 예금 38종 · 적금 59종 · 신용대출 44종. **실데이터에서 픽스처가 잡지 못한 오류 하나가 드러났다** — optionList 는 상품당 금리를 4종류 (대출금리 / 기준 / 가산 / 가감조정) 보내는데 구분 없이 최저값을 고르면 **가감조정금리(0.5%)가 대출금리로 표시된다**. 실제로 상위 3건이 0.01%·0.02%·0.1% 로 나왔다. crdt_lend_rate_type=="A" 만 쓰도록 고치고 회귀 테스트를 붙였다.

겪은 상황을 공식 자료에 실린 유형과 대조하게 한다. 판정해 주는 것이 아니라 대조표를 주는 것이며, 그 부분이 이 기능의 전부다.

입력	lang 하나뿐이다
처리	정적 카탈로그 로드 → 언어 선택(F3 와 같은 함수) → 조립. 체크 매칭은 브라우저 안에서만
출력	사기 유형 목록(원문의 단정 강도 + 근거 링크) + 대응 절차 + 신고 연락처 + 계층 항상 C
화면	S5-3 / [locale]/tools/scam — 판정 거부 안내가 대조표보다 위에 온다
검증	test_scam.py 13케이스 — 판정 필드의 부재를 테스트가 지킨다

사연을 받는 인자가 없다. "이 전화가 사기인가요?"를 실어 보낼 수 있는 파라미터를 두면 그 순간 계층 C 설계가 무너진다. 체크 상태도 서버로 보내지 않는다. 개수를 판정으로 바꾸는 임계값(예: 3개 이상이면 사기)도 두지 않는다 — 그 한 줄이 화면을 판정기로 만들고, 2개를 체크한 이용자는 "사기가 아니다"로 읽는다. 화면은 **"체크하신 항목이 알려진 유형과 n개 일치합니다"**까지만 말하고 "따라서 사기입니다"로 잊지 않는다.

근거 없는 항목은 기동에서 막는다 — 출처 URL 없는 항목이 있으면 서버가 SystemExit 로 죽는다. 사기 수법 목록은 "여기 없으면 안전하다"로 읽히기 쉬워서, 지어낸 항목 하나가 목록 전체의 신뢰를 무너뜨린다. 대응 절차의 순서(지급정지 → 신고 → 환급 신청)도 불변식으로 고정한다.

화면 구성

ID	라우트	기능
S1	/[locale]	F1
S2	/[locale]/profile	F1
S3	/[locale]/dashboard	허브
S4	/[locale]/chat	F5
—	/[locale]/institutions	F2
—	/[locale]/guide/limit-release	F4
S5-1	/[locale]/tools/checklist	F3
S5-2	/[locale]/tools/remittance	F6
—	/[locale]/tools/products	F7
S5-3	/[locale]/tools/scam	F8
—	/[locale]/terms	고지

엔드포인트

경로	기능
POST /chat	F5
POST /guide/limit-release	F4
GET /institutions	F2
GET /institutions/ranking-policy	F2
POST /checklist	F3
POST /checklist/preview	F3
POST /remittance	F6
GET /products	F7
GET /products/sort-policy	F7
GET /scam	F8
GET /healthz	운영

다국어 — 여는 것과 "검수됐다"고 말하는 것을 분리했다

언어	상태	화면 처리
한국어 (ko)	원문	기준 언어
English (en) · Tiếng Việt (vi)	원어민 검수 완료	고지 없음
中文 (zh) · O‘zbekcha (uz) · ไทย (th)	미검수	화면 상단에 미검수 고지 상시 부착 + 원문 기준(한국어) 안내

숨기는 것보다 낫다고 판단한 근거: 대상 이용자는 한국어를 못 읽는다. "준비 중"으로 막아 두면 그 이용자에게 이 서비스는 존재하지 않는 것과 같다. 다만 금액·서류명·법정 한도처럼 오역이 치명적인 항목은 여전히 번역에 맡기지 않는다 — 용어는 사전이 고정하고 숫자는 대조가 지킨다. 미검수 언어에서 무너지는 것은 문장의 자연스러움이지 값의 정확성이 아니다. 검수 목록은 서버(schemas/common.py)와 프런트(lib/i18n.ts)가 같은 목록을 갖는다.

언어를 늘릴 때는 계층 C 규칙과 골든셋을 함께 늘려야 한다. 규칙이 한국어·영어뿐이던 동안 베트남어 함정 질의가 계층 A 로 통과했다(exp_005). 번역에 기대는 2차 방어는 의도를 보존하지 못한다.

골든셋 160문항을 자동 채점 하니스가 서버 없이 파이프라인에 직접 넣어 채점한다. 아래는 최신 실험(exp_012, 로컬 Qwen3.5-4B / CUDA) 결과다.

지표	실측	목표	해석
근거 인용률	100.0%	100	폴백 제외 응답 중 인용 ≥ 1 (79/79)
숫자 정확도	100.0%	98	근거에 없는 수치가 없는 응답 비율
답변 언어 일치율	100.0%	95	요청 언어로 답했는가 — 무너지면 다른 지표가 무의미
금지표현	0건	0	0이 아니면 무조건 실패
Recall@5	93.5%	92	정답 문서가 상위 5건에 포함 (86/92)
사실 포함률	85.7%	90	미달
폴백 정확도	85.3%	95	미달 — 과잉 폴백률과 함께 볼 것
과잉 폴백률	25.0%	≤ 8	★ 미달 (아래 분해 참조)
계층 일치율	70.9%	90	★ 미달
TTFT p50 / p95	3.5s / 18.4s	—	공개 지표 (이용자 체감 지연)
총 완료 p50 / p95	21.8s / 44.7s	p95 6s	★ 미달 — 참고 지표로 계속 기록

과잉 폴백 25% 의 분해 — 절반 가까이가 "환각을 막은 것"이다

폴백 사유	건수	성격
unsupported_number	11	성질이 다르다. 근거에 없는 숫자를 잡아 막은 것 — 안전 장치가 작동한 결과다
language_mismatch	7	로컬 4B 모델이 요청 언어를 벗어난 경우
low_confidence	4	검색 신뢰도 게이트
upstream_error	1	일시 오류

골든셋 160문항의 구성 — 합정을 절반 가까이 넣었다

카테고리	문항	기대 계층 · 언어	문항
계좌개설 (account_opening)	34	A 공식 근거 명시	81
한도해제 (limit_release)	34	B 통상적 경향	45
근거 없음 (no_evidence)	34	C 개별 심사 — 답하면 실패	34
계층 C 합정 (tier_c_trap)	34		
체류·등록 (residence)	24	한국어 / English / Tiếng Việt	77 / 42 / 41

68문항(42.5%)이 "답하면 안 되는" 문항이다. 근거 없음 34 + 계층 C 합정 34. 맞는 능력만 재는 골든셋은 이 서비스의 주장을 검증하지 못한다 — 재야 하는 것은 답하지 않아야 할 때 답하지 않는가이고, 각 문항은 정답 문서 ID·포함되어야 할 사실·금지 사실·근거에 실재하는 숫자를 함께 갖는다.

자동 테스트 — 수집 536개

영역	케이스	영역	케이스
계층 판정 · 가드레일	41	스트리밍 JSON 파서	18
검색 (test_retrieval)	30	가이드 (F4)	16
요건 매트릭스 (F2)	27	해외송금 (F6)	16
숫자 정규화	27	금융상품 (F7)	15
체크리스트 (F3)	27	스키마 (F1)	15
파이프라인 · SSE	26	사기 카탈로그 (F8)	13
로컬 LLM 백엔드	20	PII 마스킹 · 토큰나이저	11 · 9

언어별 검색 임계값(실측): ko 0.8246 / en 0.8445 / vi 0.8321. 단일 임계값을 쓰면 비한국어 질의가 전부 폴백된다. 다만 en·vi 는 무근거 표본이 각각 2건·1건뿐이라 잠정값이었고, 골든셋을 100→160 으로 늘리며 확장분 60건 중 19건을 여기에 썼다(en 2→10 / vi 1→10). 측정이 못 하던 곳을 먼저 채웠다.

배포 — 단일 EC2, 외부로 나가는 호출이 없다

```
Internet :80 → nginx ┤ /api/v1, /healthz → api:10000 FastAPI + Qwen3.5-4B (CUDA)
                  └─ /                               → web:3000 Next.js standalone

g6.xlarge · ap-northeast-2 (서울)
```

검색·판정·가드레일은 원래부터 전부 로컬에서 실행됐고, 생성 모델까지 이 GPU 에서 돌면서 **국내 리전 원칙이 문구가 아니라 실제로 충족된다**. F7·F6 이 금감원·한국은행 공개 API 를 조회하지만 둘 다 없으면 없다고 말하고 지어내지 않는다. 인덱스와 모델 가중치는 업로드하지 않는다 — 리포에 있는 것만으로 인스턴스에서 재생성된다.

주요 디렉터리

apps/api/app/	
└ pipeline.py	①~⑩ 조립 (HTTP 와 분리 — 평가기가 재사용한다)
└ rag/	정규화 · 토큰라이저 · 하이브리드 검색 · 컨텍스트
└ tiering/	계층 C 규칙 · 최종 확정 ★ 안전성의 심장
└ guardrail/	인젝션 중화 · PII 마스킹
└ llm/	생성 클라이언트 · 프롬프트
└ matrix/	요건 매트릭스 · fit_score (F2) · 사기 카탈로그 (F8)
└ docs/	체크리스트 조립 · PDF 렌더 (F3)
└ tools/	ECOS · FSS 클라이언트 · 송금 계산 · 상품 비교 (F6·F7)
└ util/numerals.py	숫자 정규화 (환각 방어의 축)
corpus/	
└ sources.yaml	수집 대상 — 1차 출처만 (화이트리스트 도메인)
└ scripts/	01_fetch → 02_clean → 03_chunk → 04_index
└ matrix/	institutions · documents · remittance · scam
└ manifest.json	sha256 기록 — 근거가 바뀌면 드러난다

알려진 제약 — 숨기지 않는다

항목	내용과 판단
요건 매트릭스의 비자별 셀이 전부 unknown	은행별 계좌개설 요건의 공식 근거를 확보하지 못했다. 추정으로 채우면 그 자체가 환각이므로 비워 둔다. 기관 단위(모바일 외국인등록증 수용)는 6곳 전부 공식 근거가 있다 — 같은 보도자료의 기관 열거에서 승격했다.
F6 송금 한도가 unknown	법정 한도는 API 가 주는 값이 아니라 문서로 확인해야 하는 값이다. 근거 대장(fact-check B4·B5·B6)이 닫히기 전까지 화면에 금액이 나가지 않는다. 현재 상태를 테스트가 고정하고 있어, 그 테스트가 깨지면 근거를 함께 달아야 한다는 신호가 된다.
지연 목표를 TTFT 로 재정의	로컬 4B 의 총 완료는 p50 21.8초 / p95 44.7초라 "총 완료 P95 6초"는 달성 불가능하다. 공개 지표는 TTFT p50 3.5초 / p95 18.4초로 바꾸고, 총 완료 시간은 참고 지표로 계속 기록한다.
리랭킹 미도입 (확정)	리랭커가 Recall@5 를 93.8% → 96.9% 로 올리지만 질의당 6.8초를 더 써 지연 예산을 두 배로 넘긴다. 측정한 뒤 넣지 않기로 결정했다.

항목	내용과 판단
검색 게이트의 책임 범위	게이트가 책임지는 것은 "근거 없음" 하나뿐이다. 개별 심사 요구(계층 C)는 주제상 관련이 있어 검색 점수가 높게 나오는 것이 정상이므로, 게이트가 아니라 ㉔ 규칙과 ㉕ 계층 판정이 막는다.
PDF 는 컨테이너에서만 렌더된다	조판 엔진의 시스템 의존성이 로컬 macOS·Windows 에 없다. 로컬에서 <code>POST /checklist</code> 가 503 을 내고 화면 내 HTML 체크리스트로 폴백하는 것이 정상 이며, 컨테이너에서 503 이 나오면 그때가 고장이다.
배포 타깃 미실측	개발 GPU 와 배포 타깃의 CUDA 아키텍처가 달라 커널 경로가 같릴 수 있다. 인스턴스에서 <code>exp_012</code> 를 재현해 같은 산출물이 나오는지 확인하는 것이 수용 기준이다.

K-Buddy — 2026 금융 AI Challenge · MVP 기능 개요서 · 2026-09-07 작성
상세 명세는 docs/functional-spec.md(8항목 고정 서식) · 결정 기록은 docs/adr/ · 근거 검증 대장은 docs/fact-check.md · 실험 리포트는 eval/reports/ 에 있다.